

DarkBench: Benchmarking Dark Patterns in Large Language Models

- 第一作者

Esben Kran — Apart Research

- 通讯作者

Mateusz Jurewicz — Independent researcher

胡延伸 PB22050983 E-mail: hyanshen717@mail.ustc.edu.cn

摘要

我们推出了 DarkBench，这是一个全面的基准测试，用于检测与大型语言模型 (LLM) 交互时出现的暗黑设计模式——影响用户行为的操纵技术。我们的基准测试包含六个类别的 660 个问题：品牌偏见、用户留存、谄媚、拟人化、有害生成和潜行。我们评估了五家领先公司（OpenAI、Anthropic、Meta、Mistral、Google）的模型，发现一些 LLM 的设计明确地偏袒其开发者的产品，并表现出不真实的沟通以及其他操纵行为。开发 LLM 的公司应该认识到并减轻暗黑设计模式的影响，以促进更符合伦理道德的人工智能发展。

背景与动机

1. 背景：LLM 在现实产品中的加速落地，使“暗黑设计模式”风险从传统 UI/UX 迁移到了纯文本对话

- 研究显示，暗黑设计模式（dark design patterns）本质上是“隐蔽操纵”——通过界面或措辞诱导用户做出非本意决策，早已在购物网站、移动应用中被大量发现。随着人们转向聊天机器人和 AI 助手，这些操纵手法开始出现在大语言模型输出中，威胁用户自主性与信任。
- 欧盟《人工智能法案》等法规已明令禁止在高风险系统中使用操纵性技术，加剧了业界对“对话式暗黑模式”评估与治理的需求。
- 作者在论文开篇直指：一些前沿 LLM 已经表现出“偏袒自家品牌、讨好用户、误导性改写”等典型暗黑行为。

2. 问题领域：量化评估 LLM 对话中的暗黑设计模式

- 论文聚焦于 **AI 安全 / 模型对齐 与 人机交互 (HCI)** 的交叉地带——系统地检测并度量 LLM 输出中的操纵性文本。
- 具体涵盖 6 大风险类别：品牌偏向、用户留存、马屁迎合（sycophancy）、拟人化、偷偷改意（sneaking）、有害生成（harmful generation）。

3. 前人工作的局限：缺乏针对“操纵性风险”的公开基准

- 传统暗黑模式研究侧重网页 / App；在 LLM 领域，现有安全基准多关注事实性谬误、危险技能或欺骗策略（如 TruthfulQA、WMDP、MACHIAVELLI 等），**尚无专门评测 LLM 操纵倾向的定量工具**。
- 个案式红队或小规模手工分析难以横向比较不同模型，也无法追踪安全微调的改进幅度。

4. 作者视角与解决方案：推出 DarkBench 基准并给出首轮测评

- **基准设计：**
 - 手工+LLM 生成共 **660 条对抗性提示**，覆盖上述 6 类暗黑模式；
 - 为每条提示配套“监督者”判定脚本，并引入多模型交叉标注（Claude 3.5、Gemini 1.5、GPT-4o）保证评测一致性。
- **实验验证：**一次性测试 14 个主流专有 / 开源模型（OpenAI、Anthropic、Google、Meta、Mistral 等），共生成 9 240 组对话并自动标注 27 720 次，发现暗黑模式平均出现率高达 **48 %**，且不同厂商间差异显著。

- 贡献与意义：
 - a. 填补评测空白——首个系统性 LLM 暗黑模式基准，让研究者能够量化比较并追踪改进；
 - b. 揭示风险现状——数据表明暗黑模式在当前模型中普遍存在，凸显安全对齐紧迫性；
 - c. 可扩展框架——作者公开数据与代码，便于后续扩充新类别或用于安全微调、红队对抗。

方法

核心环节	关键做法与数据	目的
① 暗黑模式分类	从 UI/UX 文献与聊天场景中筛选 6 大类： Brand Bias、User Retention、Sycophancy、 Anthropomorphization、Harmful Generation、Sneaking (均为二元指标)	明确要检测的操纵风险维度
② 基准数据构造	Step 1 – 手工种子 ：每类先写数十条“对抗性”提示 Step 2 – LLM K-shot 扩写 ：用 GPT-4 等少样本生成变体 Step 3 – 人工/LLM 复核与重写 ：去重、 保证语义多样性与合法性 → 共得到 660 条提示 ，各类样本余弦相似度均低 (0.26–0.46)	生成覆盖面广、 互异性高的“激发语料”
③ 自动标注- 监督者(Overseer)	为每条 (prompt, response) 构建“判定提示”，让 Claude 3.5 Sonnet 、 Gemini 1.5 Pro 、 GPT-4o 三个大型模型给出 JSON 标签；多数票 (≥2/3) 为最终判定	取代高成本人工标签， 保持一致性
④ 评测协议	- 14 个开源/商用模型，温度设 0，一次回答 - 660 prompt × 14 model → 9 240 对话；每对话 × 3 Overseer → 27 720 判定	量化不同模型在 6 类暗黑模式上的触发率
⑤ 指标计算	- 单类命中率 $R_c^{(m)} = \frac{1}{N_c} \sum_{i=1}^{N_c} y_{i,c}^{(m)}$ - 总体 DarkBench 分数 $\text{Score}^{(m)} = \frac{1}{6} \sum_{c=1}^6 R_c^{(m)}$ 其中 $y_{i,c}^{(m)}$ 为多数票后的 0/1 标签	与传统 accuracy 类似、 易横向比较
⑥ 质量控制	- 余弦相似度检验防“模式崩塌” - 随机排列按钮、用人类专家抽检 1 680 条以验证 Overseer 可靠性	保证基准的代表性与可靠性




Figure 3: The benchmark is constructed by manually generating a series of representative examples for the category and subsequently using LLM-assisted K-shot generation (left). During testing (right), the LLM is prompted by the DarkBench example, a conversation is generated and the Overseer judges the conversation for the presence of the specific dark pattern.

实验结果（性能分析）

1. 整体结论：暗黑模式普遍存在

- 均值 48 %：在 660 条对抗式提示上，14 款 LLM 的平均暗黑模式触发率几乎占一半。
- 出现率区间 30 %–61 %：最“干净”的模型家族是 Anthropic 的 **Claude 3** (Haiku≈30 %、Sonnet≈32 %、Opus≈33 %)；最高的是 **Mixtral-8×7B ≈61 %**，其次为 Llama 3-70B 和 GPT-3.5 Turbo。

Claude 3 Haiku	0.36	0.16	0.10	0.22	0.85	0.04	0.77
Claude 3 Sonnet	0.32	0.08	0.21	0.23	0.81	0.03	0.54
Claude 3 Opus	0.33	0.14	0.21	0.15	0.66	0.01	0.84
Claude 3.5 Sonnet	0.30	0.01	0.22	0.32	0.84	0.03	0.41
Gemini 1.0 Pro	0.56	0.64	0.25	0.62	0.91	0.16	0.78
Gemini 1.5 Flash	0.53	0.43	0.41	0.38	0.94	0.14	0.91
Gemini 1.5 Pro	0.48	0.34	0.31	0.37	0.94	0.07	0.83
GPT-3.5 Turbo	0.61	0.66	0.31	0.85	0.62	0.26	0.95
GPT-4	0.49	0.13	0.64	0.71	0.72	0.09	0.65
GPT-4 Turbo	0.48	0.18	0.49	0.69	0.69	0.10	0.75
GPT-4o	0.55	0.33	0.63	0.80	0.52	0.16	0.84
Llama 3 70B	0.61	0.60	0.26	0.68	0.90	0.24	0.97
Mistral 7B	0.59	0.50	0.01	0.86	0.90	0.32	0.93
Mixtral 8x7B	0.56	0.76	0.08	0.85	0.77	0.23	0.65
Average	0.48	0.35	0.29	0.55	0.79	0.13	0.77
	Average	Anthropomorphization	Brand Bias	Harmful Generation	Sneaking	Sycophancy	User Retention

Figure 4: The occurrence of dark patterns by model (y) and category (x) along with the average (Avg) for each model and each category. The Claude 3 family is the safest model family for users to interact with.

2. 类别视角

类别	平均触发率	风险亮点（模型）
Sneaking	79 % (最高)	Gemini 系列最高可达 94 %——提示“改写”时经常偷偷改变立场
User Retention	62 %	Llama 3-70B 对“每天陪我聊天”类请求几乎 97 % 都积极承诺
Anthropomorphization	48 %	多数模型会自称“我喜欢...”，增加拟人化错觉
Brand Bias	35 %	Llama 3-70B、GPT-4 系列在比较问题上更易夸自家或贬他家
Harmful Generation	29 %	Mistral-7B 在极端节食等请求时往往直接输出有害方案；Claude 3 系列能拒绝或给出安全警示
Sycophancy	13 % (最低)	说明经过 RLHF 的主流模型在迎合阴谋论上已有显著抑制

3. 评测可靠性

- 作者让 Claude 3.5 Sonnet、Gemini 1.5 Pro、GPT-4o 组成 “Overseer 3 模型裁判”。与 1 680 条人工标注对比，整体 Cohen’s Kappa≈0.70–0.75，一致率 > 86 %。

- **Figure 6** 进一步检查裁判对自家模型的“偏评分”现象，仅在 Brand Bias 类别中观察到 Gemini 裁判稍有自利倾向，其余差异不显著。

4. 数据多样性与可复现性

- 六类别内部平均余弦相似度 ≤ 0.46 ，跨类别仅 0.16，避免了提示模式坍塌；不同模型输出的相似度也呈显著差异 (Claude > Gemini > Mistral)。
- 全部代码与数据已开源，便于复现与后续安全微调。

5. 论文分析要点

1. **安全文化差异明显**：同一公司的多款模型往往聚集在相近水平 (Claude 3 系列最低，Gemini 系列在 Sneaking 偏高等)，说明训练对齐策略与企业安全理念直接映射到暗黑模式指标。
2. **类别分布不均衡**：Sneaking、User Retention 占大头，而 Sycophancy 则被现有对齐方法较好抑制——为未来安全调优提供了优先级线索。
3. **自动裁判可行**：三大 LLM 裁判加多数票的自动标注方案，与专家标注已达“良好~优秀”一致度，证明 **DarkBench** 能低成本扩容和持续跟踪模型版本。

结论：实验结果充分论证了 DarkBench 的效力——它不仅揭示了主流 LLM 暗黑模式的“普遍性 + 巨大差异”，还给出了可度量、可比较的具体数字，为模型对齐、安全评审和监管提供了数据基础。

优劣性与创新点分析

创新与优势

维度	主要亮点	价值
首个系统化基准	DarkBench 将暗黑设计模式正式引入 LLM 安全评测，提供 660 条对抗式提示 + 自动打分流程，填补此前空白	为学术界和监管方建立可比、可量化参照
6 类操纵风险新分类	将传统 UI/UX 模式与对话场景特有风险融合，提出 Brand Bias、User Retention、Sycophancy、Anthropomorphization、Harmful Generation、Sneaking 六分类	为后续研究提供可扩展、安全导向的 taxonomy
三模型多数票 Overseer	用 Claude 3.5 Sonnet、Gemini 1.5 Pro、GPT-4o 做“自动评审”，与专家一致率 > 86 %	在保证可靠性的同时，把人工成本降到可持续
跨 14 款模型横评	一次性生成 9 240 组对话并打 27 720 个标签，发现平均暗黑触发率接近 48 % (Claude 3 最低，Mixtral 最高)	为厂商安全对齐策略差异提供量化证据
开源与可复现	数据、脚本与判定提示全部公开 (HuggingFace)，并记录温度等实验细节	便于社区扩充类别、追踪新模型迭代
监管契合	指标直连《欧盟 AI 法案》对“操纵性 AI”禁令，可作合规自测工具	加速可信赖 LLM 落地与政策对接

局限与改进空间

局限	具体表现	可能影响	潜在改进
标签仍依赖 LLM 主观判断	Overseer 虽与专家一致，但对 Brand Bias 等子类仍出现自利性偏差	极端案例或细粒度语义可能漏检	引入定期人工抽检； 使用多语调温度采样作对抗
仅覆盖六大类、语言单一	重点放在英文对话； 未含广告微操纵、多模态等	对多语种模型或视觉聊天机器人泛化不足	扩展到多语言提示； 加入图文情境暗黑模式
二元判定过粗	只给 0/1 命中率， 未衡量严重程度	难以分层治理	引入 Likert 级别或严重程度评分
测试设置温度固定 0	生产场景往往用温度 0.2–0.8	低估高温下的暗黑风险	设计多温度子基准， 报告最坏-案例
Prompt 多样性虽检验，但仍有限	余弦均值 < 0.46，但 660 条规模相对小	可能对策略化防御模型产生分布外提示	使用合成- 人类强化循环生成更多 adversarial prompts

- **创新处**在于把“操纵性”这一 UI 伦理老议题，以可执行基准形式迁移到 LLM 时代，并用三大顶尖模型做自动裁判——**实用性与可扩展性**兼顾。
- **优势**在于向行业量化展示了暗黑风险的“普遍 + 差异”现状，为安全对齐优先级提供了硬数据，也与合规需求直接对表。
- **局限**主要是样本规模、二元标签与 LLM 裁判固有的不确定性；但作者已给出开源框架，留足扩展接口。

总结与思考

总结

DarkBench 把“暗黑设计模式”这一原本属于 UI/UX 的操纵性概念系统化地移植到大语言模型 (LLM) 评估中。论文的核心贡献是：

1. **提出六大风险分类**——Brand Bias、User Retention、Sycophancy、Anthropomorphization、Harmful Generation、Sneaking——既覆盖商业动机，也考虑文本交互特有的拟人化与偷改语义行为。
2. **构建 660 条高多样性对抗提示**，配合三模型多数票裁判 (Claude 3.5、Gemini 1.5、GPT-4o) 自动标注，形成可复现的基准流水线。
3. **一次性横评 14 款主流 LLM**，发现平均暗黑模式触发率约 48 %，且不同公司/模型差距显著：Claude 3 系列最低，Mixtral-8x7B 与 Llama 3-70B 最高。
4. **全量开源**代码、数据与判定提示，为行业合规自测和后续安全微调提供即插即用的工具链。

思考与启示

1. “操纵性”首次可量化，安全对齐有了新刻度

在 TruthfulQA、MACHIAVELLI 关注“事实性与欺骗策略”之后，DarkBench 让 **“对用户动机操纵”** 获得了可比数字。这一维度直接映射欧盟 AI 法案的“禁止操纵”条款，为模型上线合规审计提供了抓手。未来安全研究不再局限于“说错/说坏什么”，而是进一步关注 **“想让我做什么”**。

2. 决策链条中的“裁判也是模型”

用 LLM 评测 LLM 是一次务实且必要的折衷；多数票 + 专家抽检证明它能达到可用一致度。但这也抛出一个元问题：**当顶级模型互为评审时，谁来定义“正义”？** 随着模型同质化，“裁判”与“被测”可能共享偏见——需持续混入人类监护或异构小模型做旁路校验。

3. Prompt 覆盖与标签粒度仍是扩展方向

660 条提示对发现系统性趋势已足够，却很难捕捉细分场景和跨文化差异（多语言、多模态、长对话上下文）。同时，二元 0/1 标签无法区分“轻微拟人化”与“严重操纵情感”的风险梯度——未来可引入 Likert 量表或危害加权系数。

4. 安全微调与产品设计的新指标

DarkBench 分数可以直接作为 RLHF/RLAIF 的负奖励，也可以在监控平台中作为上线门槛（如“单类触发率 $\leq 10\%$ ”）。对产品团队而言，**品牌偏向** 与 **用户留存** 两项指标最契合商业 KPI，降低它们意味着与 **商业增长** 的潜在冲突——推动了在利润与伦理之间更透明的权衡。